

Análisis de supervivencia del titanic con pandas

Integrantes:

Julián Reyes Ortiz – Líder de Datos

Juan David Prieto – Líder de Repositorio

Juan Andrés Parra – Líder de Reporte

Asignatura: Programación II

Docente: José Jorge Sierra Molina

Programa: Ciencia de Datos

Universidad Externado de Colombia

28 de mayo de 2026

1. Objetivo principal del proyecto

El objetivo principal de este proyecto es usar las herramientas de la librería Pandas en Python para limpiar, ordenar y analizar los datos del Titanic proveniente de Kaggle. La idea es trabajar en equipo usando GitHub para ver con los datos que factores (como el sexo, la edad, la clase en la que viajaban o si iban con familia) hicieron que algunas personas tuvieran más suerte que otras para salvarse en el barco

2. Principales hallazgos y análisis

Descripción del conjunto de datos y unión de variables:

Después de revisar los archivos train.csv y test.csv, identificamos variables muy importantes para analizar, como la clase del tiquete (Pclass), el sexo, la edad, los familiares a bordo (SibSp y Parch), la tarifa del pasaje (Fare), la cabina y el puerto de embarque (Embarked).

Para hacer un análisis completo que tuviera todos los pasajeros, unimos ambos dataframes de forma vertical. Antes de hacer la unión, creamos una nueva columna llamada 'Source' para identificar si cada registro pertenecía al dataframe de train o de test. Como el conjunto de prueba no incluía la columna de 'Survived', dejamos esos espacios vacíos como valores nulos 'NaN' porque no queremos inventar registros y de esta manera también podemos saber si los datos venían del dataset de train o de test. Al comparar los archivos nos dimos cuenta que los promedios eran muy parecidos, son muy consistentes entre sí, las edades promedio se acercan a los 30 años y las tarifas muestran un comportamiento muy similar, lo que demuestra que la unión de los datos fue correcta y equilibrada

Análisis de registros faltantes (Datos nulos) :

Con la librería Pandas pudimos detectar que la información no venía completa en todas las variables, identificando nulos importantes en los siguientes campos:

Edad (Age) : Faltan 177 datos en el conjunto de entrenamiento y 86 en el de prueba. Esto significa que, después de recopilar los datos, la edad exacta de algunos pasajeros no fue registrada

Cabina (Cabin) : Es la variable con más datos faltantes, 687 en train y 327 en test. Esto porque la mayoría de pasajeros viajaban en tercera clase y no tenían un camarote privado asignado, o porque no se lograron recuperar esos registros

Puerto y Tarifa: Solo hubo 2 nulos en la variable de puerto (Embarked) y 1 en la tarifa (Fare), tal vez fue un error al colocar los datos en el dataframe

3. Trabajo Colaboratorio y Control de Versiones:

Metodología de trabajo en GitHub:



Para el desarrollo del proyecto, distribuimos el trabajo utilizando ramas (branches), aunque todos hicimos de todo, cada integrante tenía asignado un rol y subió sus aportes mediante commits significativos hacia sus respectivas ramas, para luego meter esos cambios a través de Pull Requests que fueron revisados y aprobados por los compañeros del equipo

Creación y resolución del conflicto de fusión (Merge Conflict):

De acuerdo con los requerimientos de la guía, realizamos un ejercicio controlado para generar y solucionar un conflicto de fusión en GitHub Desktop

Como se provocó : Dos integrantes del equipo modificaron simultáneamente el archivo principal del proyecto. Proyecto_PRJ.ipynb, en las mismas celdas de código desde diferentes ramas. Al hacer la fusión en la rama principal, el sistema detecto que había cambios que se cruzaban y bloqueo la integración automática para evitar la pérdida de información

Como se resolvió : Como se muestra en la imagen de abajo, GitHub Desktop detecto el conflicto en el Notebook e indico que debíamos resolverlo antes de continuar. Miramos las modificaciones de cada uno y seleccionamos la opcion adecuada para combinar el trabajo de forma segura, generando el commit final para dejar la rama main perfecta



4. Conclusiones del equipo:

El desarrollo de este proyecto nos demostró que para sacar adelante un buen análisis de datos no solo se necesita saber programar, sino también trabajar coordinados en equipo. Por un lado, el uso de Pandas fue clave para organizar y entender la información que venía en las listas, limpiar los datos nulos y estructurar nuevas

variables nos permitió ver con total claridad que factores decidieron quienes se salvaban en el Titanic

Por otro lado, la experiencia con Git y GitHub nos enseñó lo importante que es llevar un control ordenado de los archivos. Gestionar ramas, revisar el trabajo de los compañeros con los Pull Requests y solucionar un conflicto de fusión real en GitHub Desktop son herramientas fundamentales que vamos a seguir usando a lo largo de toda la carrera para asegurar nuestro código